ANÁLISIS TÉCNICO DE LA MATRIZ ENERGÉTICA EN COLOMBIA 2020-2026

Claudia Arroyave, Michely Muñoz, Jesus Garcia, Maria Alejandra Colorado Ríos

Talento Tech

2026

CONTENIDO

CONTENIDO..... 2
1. INTRODUCCIÓN..... 3
2. OBJETIVOS..... 4
2.1 OBJETIVO GENERAL..... 4
2.2 OBJETIVOS ESPECÍFICOS..... 4
3. ARQUITECTURA Y ESTRUCTURA DEL CÓDIGO..... 5
3.1 NOTEBOOK..... 6
3.1.1 Configuración del entorno de trabajo..... 6
3.1.2 Construcción y descripción del conjunto de datos..... 6
3.1.3 Validación y calidad de los datos..... 7
3.1.4 Transformación y agregación de datos..... 7
3.1.5 Ingeniería de variables e indicadores..... 7
3.1.6 Análisis exploratorio de datos (EDA)..... 8
3.1.6.1 Evolución de la generación energética..... 8
3.1.6.2 Participación de las fuentes energéticas..... 9
3.1.6.3 Relación entre costos y generación..... 10
3.1.6.4 Análisis de emisiones..... 11
3.1.6.5 Evaluación de ecoeficiencia..... 12
3.1.7 Síntesis del análisis..... 12
3.2 BASE DE DATOS..... 13
3.2.1 Enfoque de modelado de datos..... 13
3.2.2 Integración con el proceso analítico (Notebook)..... 13
3.2.3 Estructura del modelo de datos..... 14
3.2.4 Tablas de dimensiones..... 15
3.2.5 Tablas de hechos..... 17
3.2.6 Integridad y calidad de los datos..... 19
3.2.7 Uso de la base de datos en la aplicación..... 20
3.2.8 Consultas analiticas clave..... 20
3.3 INTERFAZ DE USUARIO CON STREAMLIT..... 28
3.3.1 Descripción general..... 28
3.3.2 Arquitectura de la Aplicación:..... 29
3.3.3 Stack Tecnologico:..... 30
3.3.4 Módulos y funcionalidades:..... 31
4. TECNOLOGÍAS UTILIZADAS..... 38
5. GUÍA DE INSTALACIÓN Y USO..... 39
6. CONCLUSIONES..... 40

1. INTRODUCCIÓN

El presente documento técnico describe la arquitectura y el desarrollo del proyecto EnergyTransitionColombia, una solución analítica diseñada para caracterizar la evolución de la matriz energética colombiana. El sistema aborda la problemática de la diversificación mediante la comparación de fuentes hídricas, solares, eólicas y geotérmicas.

A través de un enfoque integrado que combina ciencia de datos, bases de datos relacionales y visualización web, el proyecto analiza variables críticas como la generación de energía, la demanda, la cobertura, los costos de inversión y el impacto ambiental, utilizando un horizonte temporal sintético que abarca desde el año 2020 hasta el 2026.

2. OBJETIVOS

Definir el marco técnico y metodológico para el análisis de la diversificación energética en Colombia mediante el uso de herramientas de software especializado.

2.1 OBJETIVO GENERAL

Desarrollar una plataforma analítica integral que permita evaluar la transición energética en Colombia, cruzando datos de generación, economía y regulación para facilitar la toma de decisiones técnicas.

2.2 OBJETIVOS ESPECÍFICOS

-Implementar un esquema de base de datos relacional basado en un modelo dimensional (hechos y dimensiones) para la gestión eficiente de indicadores energéticos.

-Realizar un análisis exploratorio de datos (EDA) y una ingeniería de variables para determinar el índice de diversificación y la ecoeficiencia del sistema.

-Desplegar una aplicación web interactiva que visualice los costos (LCOE, CAPEX, OPEX) y la disponibilidad de los proyectos energéticos por tipo de tecnología.

3. ARQUITECTURA Y ESTRUCTURA DEL CÓDIGO

La arquitectura del sistema se encuentra organizada en tres capas fundamentales, las cuales permiten una adecuada separación de responsabilidades y facilitan la escalabilidad y el mantenimiento del proyecto.

La **primera capa** corresponde al Notebook de análisis (*Transicion_Energetica.ipynb*), en el cual se realiza el proceso de limpieza, transformación y análisis de los datos. En esta etapa se generan indicadores derivados a partir de datos sintéticos, inspirados en fuentes oficiales como la UPME (Unidad de Planeación Minero Energética) y el SGC (Servicio Geológico Colombiano).

La **segunda capa** está conformada por la base de datos en MySQL, estructurada bajo un esquema dimensional denominado *MatrizEnergeticaCol*.sql.

Este modelo sigue un enfoque de tipo estrella, incluyendo tablas de hechos como *Fact_Generacion* y *Fact_Costos*, así como tablas de dimensiones que permiten clasificar la información relacionada con regulación, fuentes y tipos de energía. Esta estructura garantiza la integridad referencial mediante el uso de claves foráneas y tipos de datos explícitos, dejando el sistema preparado para procesos de auditoría y futura integración con datos reales.

La **tercera capa** corresponde a la interfaz de usuario desarrollada en Streamlit (*streamlit_app.py*), la cual funciona como un dashboard interactivo. Esta permite la visualización de indicadores en tiempo real y facilita la consulta y análisis de proyectos energéticos según criterios como viabilidad económica y cumplimiento normativo.

El detalle completo del proyecto, incluyendo código fuente y documentación, se encuentra disponible en el repositorio de GitHub:

https://github.com/malejaDev/EnergyTransitionColombia/tree/master

3.1 NOTEBOOK

Repositorio:
https://github.com/malejaDev/EnergyTransitionColombia/tree/master/notebook

El Notebook *Transicion_Energetica.ipynb* constituye el componente central de análisis del presente proyecto, en el cual se desarrollan los procesos de preparación, transformación y análisis de datos orientados a la evaluación de la transición energética en Colombia.

3.1.1 Configuración del entorno de trabajo

El entorno de análisis fue implementado en Python, utilizando librerías especializadas para el procesamiento y visualización de datos. Entre las principales herramientas empleadas se encuentran:

- **pandas** y **numpy**, para la manipulación y estructuración de datos
- **matplotlib** y **seaborn**, para la generación de visualizaciones

Esta configuración permite garantizar la reproducibilidad del análisis y la consistencia en la generación de resultados.

3.1.2 Construcción y descripción del conjunto de datos

El conjunto de datos utilizado es de carácter sintético, diseñado para simular el comportamiento de la matriz energética colombiana en el periodo comprendido entre 2020 y 2026.

Las variables consideradas incluyen:

- Generación energética
- Demanda y oferta
- Costos de producción
- Inversión
- Emisiones de CO_2
- Tipo de fuente energética (solar, eólica, hídrica, geotérmica)

3.1.3 Validación y calidad de los datos

Previo al análisis, se realizó un proceso de validación orientado a garantizar la consistencia y confiabilidad del conjunto de datos. Este incluyó:

- Verificación de tipos de datos
- Identificación y tratamiento de valores nulos
- Revisión de rangos y valores atípicos
- Validación de coherencia entre variables relacionadas

Este proceso resulta fundamental para asegurar la integridad del análisis y evitar sesgos en la interpretación de resultados.

3.1.4 Transformación y agregación de datos

Con el fin de facilitar el análisis, se construyó una base agregada que consolida la información por año y tipo de fuente energética. Esta transformación permite:

- Reducir la complejidad del conjunto de datos original
- Identificar patrones temporales
- Comparar el comportamiento entre diferentes tecnologías

La agregación constituye un paso clave para la construcción de indicadores y la posterior visualización de resultados.

3.1.5 Ingeniería de variables e indicadores

A partir de los datos procesados, se desarrolló un conjunto de indicadores derivados que permiten analizar la transición energética desde múltiples dimensiones.

Entre los principales indicadores se destacan:

- Participación porcentual por fuente energética
- Crecimiento interanual de la generación
- Costo por unidad de energía generada

- Intensidad de emisiones
- Índice de ecoeficiencia
- Emisiones evitadas
- Índice de diversificación de la matriz energética

Estos indicadores permiten evaluar simultáneamente aspectos económicos, ambientales y estructurales del sistema energético.

3.1.6 Análisis exploratorio de datos (EDA)

El análisis exploratorio se enfoca en la identificación de patrones, tendencias y relaciones entre variables clave del sistema energético.

3.1.6.1 Evolución de la generación energética

El análisis de la evolución temporal permite identificar tendencias de crecimiento o decrecimiento en las diferentes fuentes energéticas.

Figura 1. ***Evolución de la generación por tipo de energía (2020–2026)***

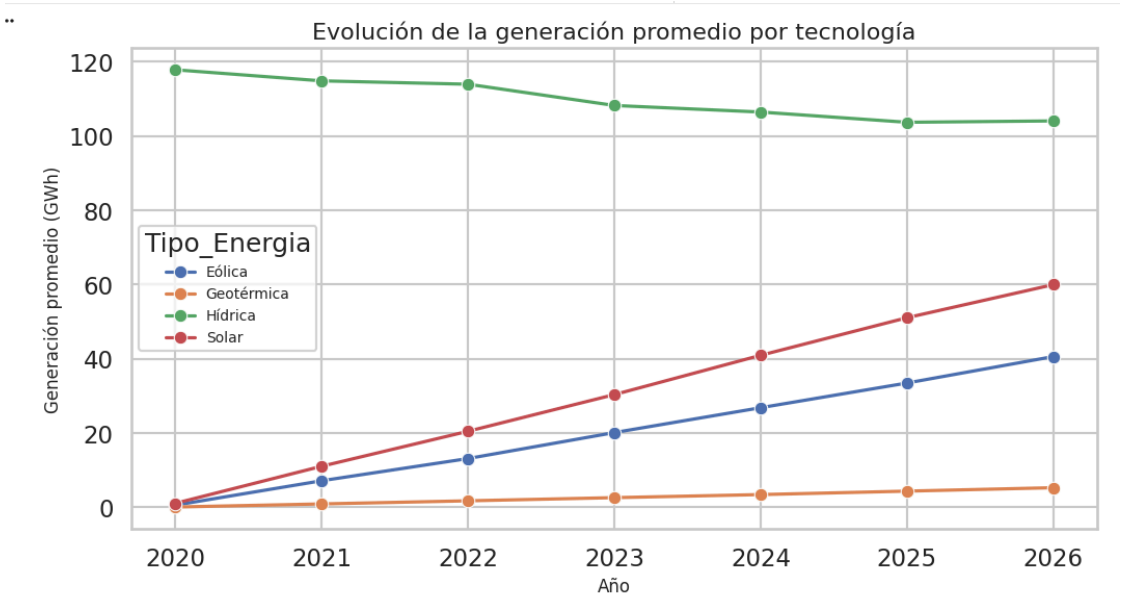

Nota.Imagen del notebook Transicion_Energetica.ipynb.

Análisis:

Como se observa en la figura 1, la trayectoria sintética sugiere una

expansión acelerada de la energía solar y eólica, una entrada gradual pero aún marginal de la geotermia y una reducción relativa de la fuente hídrica. Esto apunta a un patrón de diversificación, aunque la hidroelectricidad conserva una escala dominante durante todo el periodo.

3.1.6.2 Participación de las fuentes energéticas

Figura 2. ***Participación porcentual por tipo de energía***

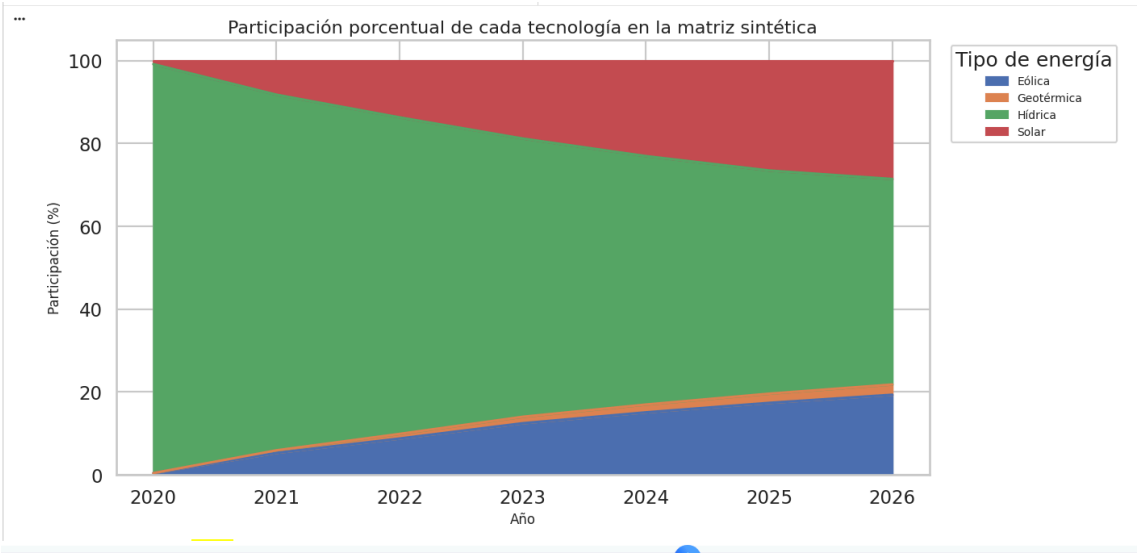

Nota.Imagen del notebook Transicion_Energetica.ipynb.

Análisis:

De acuerdo a la figura 2, la distribución porcentual evidencia la predominancia de ciertas fuentes tradicionales (hídrica), aunque se observa un incremento gradual en la participación de energías limpias (solar y eólica).

3.1.6.3 Relación entre costos y generación

Figura 3. ***Costos vs generación energética***

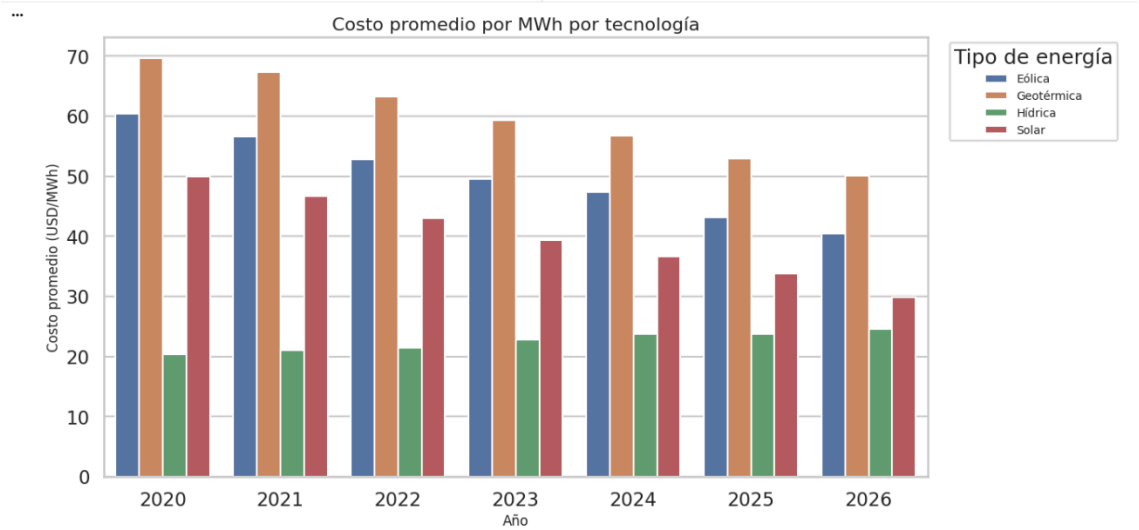

Nota.Imagen del notebook Transicion_Energetica.ipynb.

Análisis:

De acuerdo a la figura 3, la hidroelectricidad se mantiene como la tecnología de menor costo en la simulación, aunque con una ligera tendencia al alza. La solar y la eólica reducen su costo a lo largo del tiempo, mejorando la competitividad. La geotermia conserva costos relativamente altos, lo que refuerza su papel como tecnología estratégica de nicho más que como fuente de masificación inmediata.

3.1.6.4 Análisis de emisiones

Figura 4. ***Emisiones de CO_2 por tipo de energía***

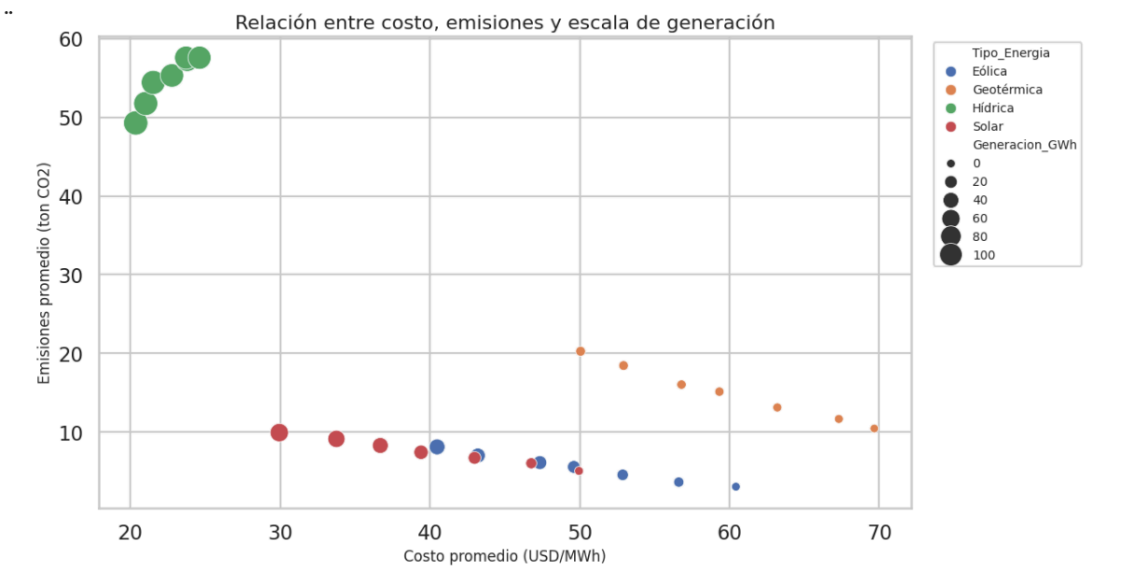

Nota.Imagen del notebook Transicion_Energetica.ipynb.

Análisis:

Según el diagrama de dispersión de la figura 4, las fuentes renovables presentan menores niveles de emisiones, lo que refuerza su relevancia en el contexto de sostenibilidad ambiental. La hídrica combina bajo costo con alta escala, pero no necesariamente con la menor intensidad relativa de emisiones en este ejercicio sintético. Adicional, las energía Solar y eólica se ubican como alternativas de menor impacto absoluto, mientras la geotermia combina baja escala y costo elevado.

3.1.6.5 Evaluación de ecoeficiencia

Figura 5. ***Indicadores de ecoeficiencia***

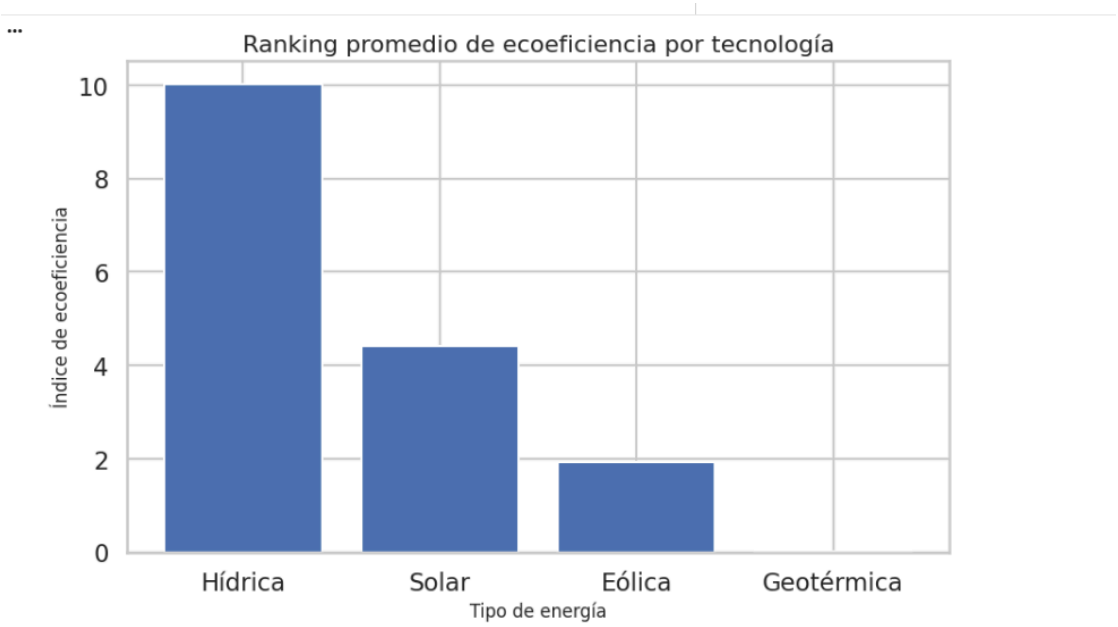

Nota.Imagen del notebook Transicion_Energetica.ipynb.

Análisis:

La ecoeficiencia permite identificar aquellas tecnologías que logran un equilibrio óptimo entre generación energética y reducción de impacto ambiental.

3.1.7 Síntesis del análisis

El desarrollo del Notebook permitió consolidar un marco analítico robusto para la evaluación de la transición energética en Colombia. A través de la aplicación de técnicas de análisis de datos, generación de indicadores y visualización de información, se logró identificar tendencias clave y relaciones relevantes entre variables del sistema energético.

Este componente constituye la base para la construcción del modelo de datos y la posterior implementación de herramientas de visualización, descritas en las siguientes secciones del documento.

3.2 BASE DE DATOS

Repositorio:

https://github.com/malejaDev/EnergyTransitionColombia/tree/master/database

La base de datos del proyecto constituye el componente encargado de la persistencia, organización y consulta eficiente de la información generada durante la fase analítica. Esta fue implementada en MySQL bajo un enfoque de modelado dimensional, con el objetivo de soportar procesos analíticos, consultas agregadas y visualización de indicadores estratégicos.

3.2.1 Enfoque de modelado de datos

El diseño de la base de datos se fundamenta en un **modelo dimensional tipo estrella (star schema)**, el cual es ampliamente utilizado en sistemas de analítica y Business Intelligence debido a su simplicidad, rendimiento en consultas y facilidad de interpretación.

Este modelo se compone de:

- **Tablas de hechos**, que almacenan métricas cuantitativas del sistema
- **Tablas de dimensiones**, que permiten contextualizar y segmentar dichas métricas

3.2.2 Integración con el proceso analítico (Notebook)

La estructura de la base de datos fue diseñada a partir de los resultados obtenidos en el Notebook *Transicion_Energetica.ipynb*, en donde se definieron las variables clave, indicadores derivados y relaciones conceptuales del sistema energético.

En este sentido, el flujo de construcción de la base de datos sigue el siguiente proceso:

1. **Generación de datos sintéticos en el Notebook**, incluyendo variables como generación, costos, emisiones y capacidad instalada
2. **Transformación y agregación de datos**, para estructurar la información a nivel de análisis
3. **Identificación de entidades principales**, como proyectos, tipos de energía y regulación
4. **Diseño del modelo dimensional**, separando hechos y dimensiones
5. **Carga de datos en MySQL**, garantizando integridad y consistencia

Este enfoque garantiza coherencia entre el análisis exploratorio y la capa de persistencia, permitiendo que los datos consumidos por la aplicación sean consistentes con los resultados analíticos.

3.2.3 Estructura del modelo de datos

A continuación, se presenta el modelo relacional implementado:

Figura 6. *Modelo dimensional de la base de datos*

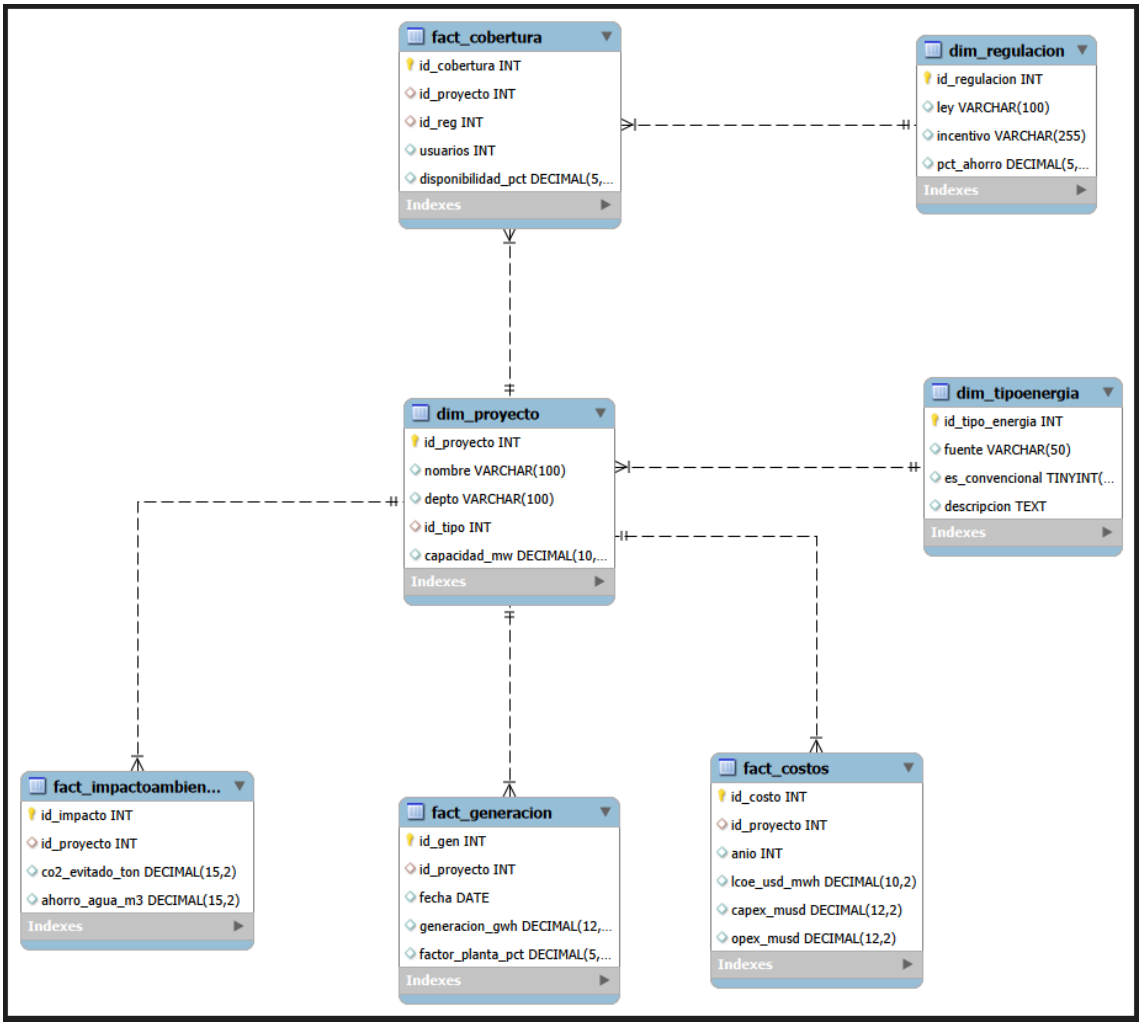

3.2.4 Tablas de dimensiones

Las tablas de dimensiones permiten describir y categorizar la información contenida en las tablas de hechos.

- **Dimensión Proyecto (dim_proyecto)**

  Contiene la información general de los proyectos energéticos, incluyendo:

  - Nombre del proyecto
  - Ubicación (departamento)
  - Tipo de energía
  - Capacidad instalada

Esta dimensión actúa como eje central del modelo, conectando múltiples hechos.

Figura 7. *Estructura de la tabla 'dim_proyecto'*

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

Field	Type	Null	Key	Default	Extra
id_proyecto	int	NO	PRI	NULL	
nombre	varchar(100)	YES		NULL	
depto	varchar(100)	YES		NULL	
id_tipo	int	YES	MUL	NULL	
capacidad_mw	decimal(10,2)	YES		NULL	

- **Dimensión Tipo de Energía (dim_tipoenergia)**

Clasifica las fuentes energéticas según su naturaleza, permitiendo diferenciar entre energías convencionales y no convencionales.

Figura 8. *Estructura de la tabla '**dim_tipoenergia**'*

Result Grid | Filter Rows: | Export: | Wrap Cell C

Field	Type	Null	Key	Default	Extra
id_tipo_energia	int	NO	PRI	NULL	
fuente	varchar(50)	YES		NULL	
es_convencional	tinyint(1)	YES		NULL	
descripcion	text	YES		NULL	

YES

- **Dimensión Regulación (dim_regulacion)**

Incluye información relacionada con el marco normativo, incentivos y beneficios asociados a los proyectos energéticos.

Figura 8. *Estructura de la tabla* '**dim_regulacion**'

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

	Field	Type	Null	Key	Default	Extra
▶	id_regulacion	int	NO	PRI	NULL	
	ley	varchar(100)	YES		NULL	
	incentivo	varchar(255)	YES		NULL	
	pct_ahorro	decimal(5,2)	YES		NULL	

3.2.5 Tablas de hechos

Las tablas de hechos contienen las métricas principales del sistema:

- **Fact_Generacion (fact_generacion)**

  Almacena la generación energética por proyecto y fecha, incluyendo:

  - Energía generada
  - Factor de planta

  Permite analizar la evolución temporal del sistema.

  Figura 9. *Estructura de la tabla* '**fact_generacion**'

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

	Field	Type	Null	Key	Default	Extra
▶	id_gen	int	NO	PRI	NULL	auto_increment
	id_proyecto	int	YES	MUL	NULL	
	fecha	date	YES		NULL	
	generacion_gwh	decimal(12,4)	YES		NULL	
	factor_planta_pct	decimal(	decimal(12,4)		NULL	

- **Fact_Costos (fact_costos)**

Contiene información económica de los proyectos:

- Costo nivelado de energía (LCOE)
- CAPEX (inversión inicial)
- OPEX (costos operativos)

Esta tabla es clave para evaluar la viabilidad financiera.

Figura 10. *Estructura de la tabla* **'fact_costos'**

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

Field	Type	Null	Key	Default	Extra
id_costo	int	NO	PRI	NULL	auto_increment
id_proyecto	int	YES	MUL	NULL	
anio	int	YES		NULL	
lcoe_usd_mwh	decimal(10,2)	YES		NULL	
capex_musd	decimal(12,2)	YES		NULL	
opex_musd	decimal(12,2)	YES		NULL	

- **Fact_ImpactoAmbiental (fact_impactoambiental)**

Registra indicadores ambientales:

- Emisiones de CO_2
- Ahorro de agua

Permite evaluar el impacto ecológico de cada tecnología.

Figura 11. *Estructura de la tabla* **'fact_impactoambiental'**

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

Field	Type	Null	Key	Default	Extra
id_impacto	int	NO	PRI	NULL	auto_increment
id_proyecto	int	YES	MUL	NULL	
co2_evitado_ton	decimal(15,2)	YES		NULL	
ahorro_agua_m3	decimal(15,2)	YES		NULL	

- **Fact_Cobertura (fact_cobertura)**

  Incluye métricas relacionadas con:

  - Usuarios beneficiados
  - Disponibilidad del servicio

  Facilita el análisis del impacto social de los proyectos.

  Figura 12. *Estructura de la tabla* **'fact_cobertura'**

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

Field	Type	Null	Key	Default	Extra
id_cobertura	int	NO	PRI	NULL	auto_increment
id_proyecto	int	YES	MUL	NULL	
id_reg	int	YES	MUL	NULL	
usuarios	int	YES		NULL	
disponibilidad_pct	decimal(5,2)	YES		NULL	

3.2.6 Integridad y calidad de los datos

Para garantizar la confiabilidad del sistema, se implementaron las siguientes prácticas:

- Definición de **claves primarias y foráneas**

- Uso de **tipos de datos explícitos** (DECIMAL, INT, DATE)
- Validación de relaciones entre tablas
- Estructuración consistente con el modelo analítico

Esto permite asegurar la integridad referencial y la coherencia de los datos almacenados.

3.2.7 Uso de la base de datos en la aplicación

La base de datos actúa como fuente principal de información para la aplicación desarrollada en Streamlit, permitiendo:

- Consultas dinámicas de indicadores
- Filtrado por tipo de energía y ubicación
- Evaluación de proyectos según criterios económicos y ambientales

De esta manera, la base de datos no solo cumple un rol de almacenamiento, sino que se convierte en un componente activo dentro del proceso de toma de decisiones.

3.2.8 Consultas analiticas clave

A continuación se presentan cinco consultas SQL seleccionadas por su relevancia estratégica para el análisis de la transición energética colombiana.

Cada consulta es documentada con su justificación técnica, la interpretación esperada de sus resultados, su vinculación con la agenda de transición energética y una propuesta de visualización adecuada para comunicar los hallazgos a audiencias técnicas y de política pública.

- **Q01: Generación total (GWh) por fuente energética:**

```sql
SELECT
    t.fuente,
    SUM(g.generacion_gwh) AS total_gwh
FROM Fact_Generacion g
JOIN Dim_Proyecto p
    ON p.id_proyecto = g.id_proyecto
JOIN Dim_TipoEnergia t
    ON t.id_tipo_energia = p.id_tipo
GROUP BY t.fuente
ORDER BY total_gwh DESC;
```

Resultado:

Result Grid | Filter Rows:

fuente	total_gwh
Hidráulica	8024.4455
Eólica	637.0520
Solar	177.7275
Geotérmica	153.8407

Análisis:

Los resultados de la consulta Q01 evidencian una matriz energética altamente concentrada en la generación hidráulica, que acumula 8.024 GWh y representa aproximadamente el 94% de la generación total registrada. Las fuentes no convencionales —eólica (637 GWh), solar (178 GWh) y geotérmica (154 GWh)— contribuyen de forma marginal, sumando en conjunto apenas el 6% restante.

Esta composición refleja la dependencia estructural del sistema eléctrico colombiano respecto al recurso hídrico, condición que lo expone a riesgos significativos ante fenómenos climáticos como El Niño. Al mismo tiempo, la baja participación de las FNCE evidencia un amplio margen de diversificación, lo que refuerza la pertinencia de políticas orientadas a acelerar la incorporación de energías renovables no convencionales en la matriz nacional.

- **Q02: LCOE promedio por fuente energética**

```sql
SELECT
    t.fuente,
    AVG(c.lcoe_usd_mwh) AS lcoe_promedio_usd_mwh
FROM Fact_Costos c
JOIN Dim_Proyecto p
    ON p.id_proyecto = c.id_proyecto
JOIN Dim_TipoEnergia t
    ON t.id_tipo_energia = p.id_tipo
GROUP BY t.fuente
ORDER BY lcoe_promedio_usd_mwh ASC;
```

Resultado:

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

fuente	lcoe_promedio_usd_mwh
Geotérmica	42.340000
Hidráulica	46.125000
Eólica	61.775000
Solar	70.215000

Análisis:

Los resultados de la consulta Q02 muestran el costo nivelado de energía (LCOE) promedio por fuente. La geotérmica presenta el valor más bajo con 42,34 USD/MWh, seguida de la hidráulica con 46,13 USD/MWh. La eólica se ubica en 61,78 USD/MWh y la solar registra el mayor costo con 70,22 USD/MWh.

Estos valores indican que, en el contexto de los proyectos analizados, la generación hidráulica y geotérmica resultan económicamente más competitivas. Sin embargo, es importante considerar que el LCOE de las tecnologías solar y eólica ha mostrado una tendencia de reducción sostenida a nivel global, por lo que su posición relativa puede variar a medida que maduren los mercados y se escale la capacidad instalada

en el país. En ese sentido, los datos no descartan la viabilidad futura de estas fuentes, sino que señalan la necesidad de mecanismos de financiamiento y políticas de incentivo que reduzcan su costo de entrada al sistema energético colombiano.

- **Q03: CO2 evitado y ahorro de agua por fuente energética:**

```
SELECT
    t.fuente,
    SUM(i.co2_evitado_ton) AS co2_evitado_total_ton,
    SUM(i.ahorro_agua_m3)  AS ahorro_agua_total_m3
FROM Fact_ImpactoAmbiental i
JOIN Dim_Proyecto p
    ON p.id_proyecto = i.id_proyecto
JOIN Dim_TipoEnergia t
    ON t.id_tipo_energia = p.id_tipo
GROUP BY t.fuente
ORDER BY co2_evitado_total_ton DESC;
```

Resultado:

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

fuente	co2_evitado_total_ton	ahorro_agua_total_m3
Hidráulica	4877550.00	0.00
Eólica	707400.00	78600.00
Solar	360450.00	40050.00
Geotérmica	67500.00	7500.00

Análisis:

Los resultados de la consulta Q03 presentan dos indicadores ambientales por fuente: toneladas de CO_2 evitadas y metros cúbicos de agua ahorrados. La generación hidráulica lidera ampliamente en CO_2 evitado con 4.877.550 toneladas, resultado coherente con su predominancia en el volumen total de generación. Le siguen la eólica con 707.400 ton y la solar con 360.450 ton, mientras que la geotérmica registra la menor contribución con 67.500 ton.

No obstante, el indicador de ahorro de agua revela un contraste relevante: la hidráulica registra 0 m³ de ahorro, dado que su operación depende precisamente del consumo del recurso hídrico. En cambio, la eólica ahorra 78.600 m³ y la solar 40.050 m³, lo que las posiciona como alternativas ambientalmente más integrales en contextos de estrés hídrico. Este hallazgo es significativo para Colombia, donde la presión sobre las cuencas hidrográficas es creciente y la generación hidráulica compite directamente con el suministro de agua potable y los ecosistemas acuáticos. La diversificación hacia fuentes eólica y solar, por tanto, no solo contribuye a la descarbonización sino también a la sostenibilidad del recurso hídrico nacional.

- **Q04: Proyectos con CAPEX superior al promedio de su propia fuente:**

```sql
SELECT
    p.id_proyecto,
    p.nombre AS proyecto,
    t.fuente,
    c.capex_musd
FROM Dim_Proyecto p
JOIN Dim_TipoEnergia t
    ON t.id_tipo_energia = p.id_tipo
JOIN Fact_Costos c
    ON c.id_proyecto = p.id_proyecto
WHERE c.capex_musd > (
    SELECT AVG(c2.capex_musd)
    FROM Fact_Costos c2
    JOIN Dim_Proyecto p2
        ON p2.id_proyecto = c2.id_proyecto
    WHERE p2.id_tipo = p.id_tipo
)
ORDER BY t.fuente, c.capex_musd DESC;
```

Resultado:

Result Grid | Filter Rows: | Export:

id_proyecto	proyecto	fuente	capex_musd
302	Alpha Wind	Eólica	554.40
101	Hidroituango	Hidráulica	2640.00
201	La Loma	Solar	205.70

Análisis:

Los resultados de la consulta Q04 identifican los proyectos cuyo CAPEX supera el promedio de inversión de su propia fuente energética. Hidroituango encabeza la lista con 2.640 MUSD, valor que refleja la escala y complejidad característica de los grandes proyectos hidroeléctricos en Colombia. Alpha Wind, con 554,40 MUSD, supera el promedio del segmento eólico, lo que puede explicarse por su ubicación en La Guajira y los costos asociados a infraestructura de conexión y transporte. La Loma, proyecto solar con 205,70 MUSD, también excede el promedio de su categoría.

El hecho de que los tres proyectos identificados pertenezcan a fuentes distintas indica que el sobrecosto relativo no es exclusivo de una tecnología, sino que responde a condiciones específicas de cada proyecto: capacidad instalada, ubicación geográfica y contexto de desarrollo. Para la política de transición energética, estos casos señalan la importancia de diseñar instrumentos financieros diferenciados que permitan a proyectos con CAPEX elevado acceder a estructuras de financiamiento de largo plazo, evitando que el costo inicial se convierta en una barrera de entrada para las energías renovables.

- **Q05: Resumen integral por proyecto: generacion, costo, impacto y cobertura:**

```sql
SELECT
    p.id_proyecto,
    p.nombre AS proyecto,
    t.fuente,
    SUM(g.generacion_gwh)  AS total_gwh,
    c.lcoe_usd_mwh,
    i.co2_evitado_ton,
    cb.usuarios,
    cb.disponibilidad_pct
FROM Dim_Proyecto p
JOIN Dim_TipoEnergia t
    ON t.id_tipo_energia = p.id_tipo
LEFT JOIN Fact_Generacion g
    ON g.id_proyecto = p.id_proyecto
LEFT JOIN Fact_Costos c
    ON c.id_proyecto = p.id_proyecto
LEFT JOIN Fact_ImpactoAmbiental i
    ON i.id_proyecto = p.id_proyecto
LEFT JOIN Fact_Cobertura cb
    ON cb.id_proyecto = p.id_proyecto
GROUP BY
    p.id_proyecto, p.nombre, t.fuente,
    c.lcoe_usd_mwh, i.co2_evitado_ton,
    cb.usuarios, cb.disponibilidad_pct
ORDER BY total_gwh DESC;
```

Resultado:

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

id_proyecto	proyecto	fuente	total_gwh	lcoe_usd_mwh	co2_evitado_ton	usuarios	disponibilidad_pct
101	Hidroituango	Hidráulica	5299.3755	47.54	3240000.00	1080000	98.50
102	Guavio	Hidráulica	2725.0700	44.71	1637550.00	545850	98.50
302	Alpha Wind	Eólica	612.9959	82.13	680400.00	226800	98.50
401	Nereidas	Geotérmica	153.8407	42.34	67500.00	22500	98.50
201	La Loma	Solar	128.9905	68.64	252450.00	84150	98.50
202	Celsia Solar	Solar	48.7370	71.79	108000.00	36000	98.50
301	Guajira I	Eólica	24.0561	41.42	27000.00	9000	98.50

Análisis:

Los resultados de la consulta Q27 consolidan en una sola vista los indicadores técnicos, económicos, ambientales y sociales de cada proyecto. Hidroituango lidera en generación con 5.299 GWh y en CO_2 evitado con 3.240.000 toneladas, beneficiando a 1.080.000 usuarios, lo que lo convierte en el proyecto de mayor impacto absoluto del portafolio.

Guavio, también hidráulico, sigue una lógica similar aunque a menor escala.

Entre las FNCE, Alpha Wind destaca con 612 GWh generados y 680.400 toneladas de CO_2 evitado, consolidándose como el proyecto renovable no convencional más relevante del conjunto. Sin embargo, su LCOE de 82,13 USD/MWh es el más alto, lo que evidencia la tensión entre impacto ambiental y competitividad económica que caracteriza a las tecnologías eólicas en etapa de maduración. Nereidas, el único proyecto geotérmico, presenta el LCOE más bajo de todas las FNCE (42,34 USD/MWh), sugiriendo un potencial subestimado de esta tecnología en Colombia.

Un dato transversal relevante es que todos los proyectos registran una disponibilidad del 98,50%, lo que indica un sistema operativamente confiable en su conjunto. Esta vista integral permite concluir que la matriz actual combina alta confiabilidad y gran volumen de generación limpia, pero con una concentración excesiva en fuentes hídricas y un desarrollo aún incipiente de las renovables no convencionales, ratificando la necesidad de una transición energética activa y sostenida.

3.3 INTERFAZ DE USUARIO CON STREAMLIT

Repositorio:

https://github.com/malejaDev/EnergyTransitionColombia/tree/master

Aplicación Desplegada:

https://energytransitioncolombia.streamlit.app/

3.3.1 Descripción general

La interfaz de usuario fue desarrollada utilizando Streamlit, un framework de código abierto basado en Python que permite construir aplicaciones web interactivas orientadas al análisis y visualización de datos sin requerir conocimientos avanzados de desarrollo frontend. Esta elección tecnológica responde a la naturaleza exploratoria del proyecto, donde la prioridad es facilitar la interpretación de grandes volúmenes de datos energéticos de forma dinámica, accesible y reproducible.

La aplicación constituye la capa de presentación del sistema de análisis de la transición energética en Colombia, integrando los resultados del procesamiento y modelado de datos en un entorno visual e interactivo. A través de gráficos dinámicos, indicadores clave de desempeño (KPIs) y controles de filtrado, la herramienta permite al usuario explorar las tendencias históricas, la composición de la matriz energética y las proyecciones del sector, apoyando así la toma de decisiones basada en evidencia.

Figura 13. ***Vista general de la interfaz principal de la aplicación EnergyTransitionColombia.***

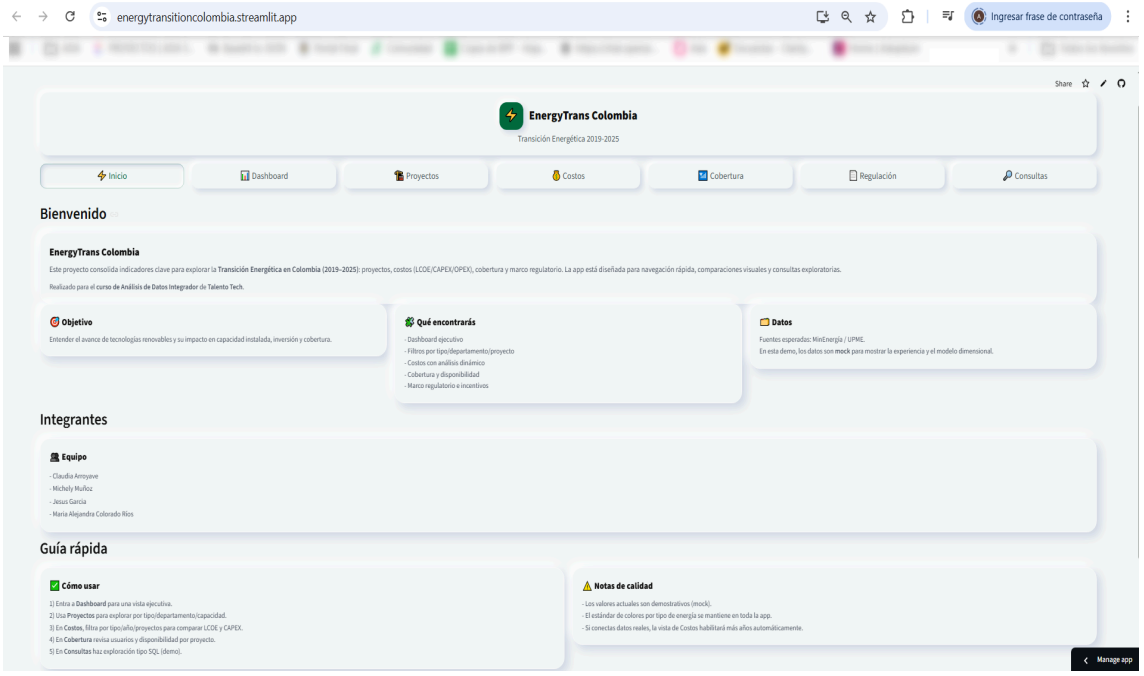

3.3.2 Arquitectura de la Aplicación:

La aplicación sigue una arquitectura modular organizada en páginas independientes, característica del modo multipágina de Streamlit. La estructura del repositorio es la siguiente:

```
EnergyTransitionColombia/
|
├── .streamlit/            # Configuración de tema y apariencia de la app
├── __pycache__/           # Caché de módulos Python (generado automáticamente)
├── database/              # Datos procesados utilizados por la aplicación
├── notebook/              # Notebooks de exploración y análisis previo
├── tests/                 # Pruebas y validaciones del proyecto
├── streamlit_app.py       # Punto de entrada principal de la aplicación
├── requirements.txt       # Dependencias del proyecto
└── README.md              # Documentación general del repositorio
```

El archivo central de la interfaz es **`streamlit_app.py`**, que concentra la lógica de visualización e interacción. Los datos procesados residen en la

carpeta **`database/`**, la cual alimenta directamente las visualizaciones de la app. La carpeta **`notebook/`** contiene los análisis exploratorios y de procesamiento que precedieron al desarrollo de la interfaz, representando el puente entre la exploración de datos y su presentación final. La carpeta **`tests/`** agrupa las validaciones realizadas sobre los datos y componentes del sistema. La configuración visual de la aplicación —paleta de colores, fuentes y tema— se gestiona desde el directorio **`.streamlit/`** mediante el archivo `config.toml`.

El flujo de datos dentro de la aplicación opera de la siguiente manera: los datos pre procesados almacenados en `database/` son cargados por `streamlit_app.py`, filtrados según los parámetros seleccionados por el usuario a través de los controles interactivos, y finalmente renderizados como visualizaciones dinámicas en el navegador.

3.3.3 Stack Tecnologico:

La Tabla 3.3.1 resume las principales tecnologías y librerías utilizadas en el desarrollo de la interfaz de usuario.

Tecnología / Librería	Versión mínima	Rol en la aplicación
Python	3.10+	Lenguaje base de desarrollo
Streamlit	1.37	Framework principal de la interfaz web interactiva
Pandas	2.2	Carga, manipulación y transformación de los datos energéticos
Altair	5.3	Generación de visualizaciones declarativas e interactivas
Pytest	8.0	Framework de pruebas unitarias y validación del proyecto
Streamlit Community Cloud	—	Plataforma de despliegue y hosting gratuito

3.3.4 Módulos y funcionalidades:

La aplicación está organizada en siete vistas o módulos de navegación, implementados como funciones independientes y accesibles mediante una barra de navegación horizontal ubicada en la parte superior de la interfaz. A continuación se describe cada módulo.

a) Inicio

Constituye la pantalla de bienvenida del sistema. Presenta el contexto del proyecto mediante tarjetas informativas que describen el objetivo del análisis, el contenido disponible en cada sección y la naturaleza de los datos utilizados. Incluye además la identificación del equipo de trabajo y una guía rápida de uso que orienta al usuario sobre cómo navegar la aplicación de forma eficiente. Finaliza con notas de calidad que advierten al usuario sobre el carácter demostrativo (mock) de los datos en la versión actual.

Figura 3.2. Módulo de Inicio con tarjetas de presentación y guía de uso.

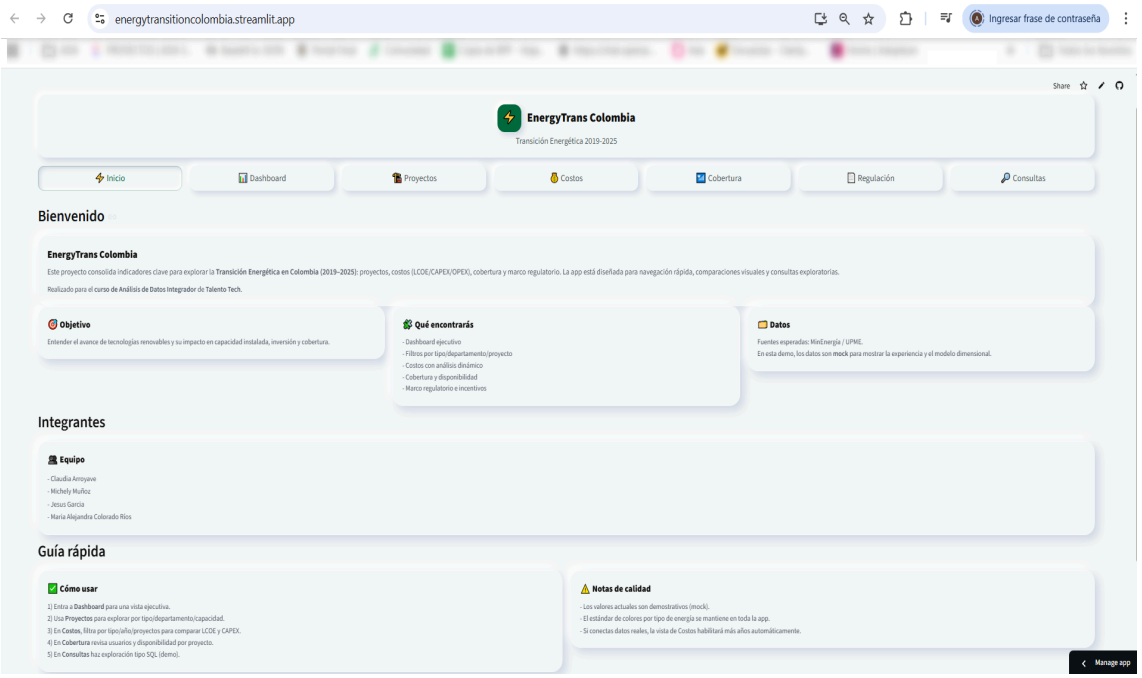

b) Dashboard

Es el módulo central de la aplicación. Presenta seis indicadores KPI en tarjetas de resumen ejecutivo: número de proyectos activos, capacidad total instalada (GW), inversión total (CAPEX), usuarios beneficiados, LCOE promedio y porcentaje de energía renovable. Complementa estos indicadores con cuatro visualizaciones interactivas generadas con Altair:

- Gráfico de dona: distribución de la capacidad instalada (MW) por tipo de fuente energética.
- Gráfico de barras: LCOE comparativo por tecnología para el año más reciente disponible.
- Gráfico de barras agrupadas: inversión CAPEX versus OPEX por proyecto.
- Gráfico de dona: distribución de usuarios beneficiados por proyecto.

Cada gráfico incorpora un componente expandible de interpretación automática que genera un resumen estadístico dinámico —incluyendo máximos, mínimos, mediana, IQR y participación relativa— calculado directamente sobre los datos en pantalla. El módulo cierra con tarjetas de los cuatro tipos de energía renovable considerados (hidráulica, solar, eólica y geotérmica), mostrando la capacidad instalada total por tecnología.

Figura 3.3. Módulo Dashboard con indicadores KPI y visualizaciones del mix energético.

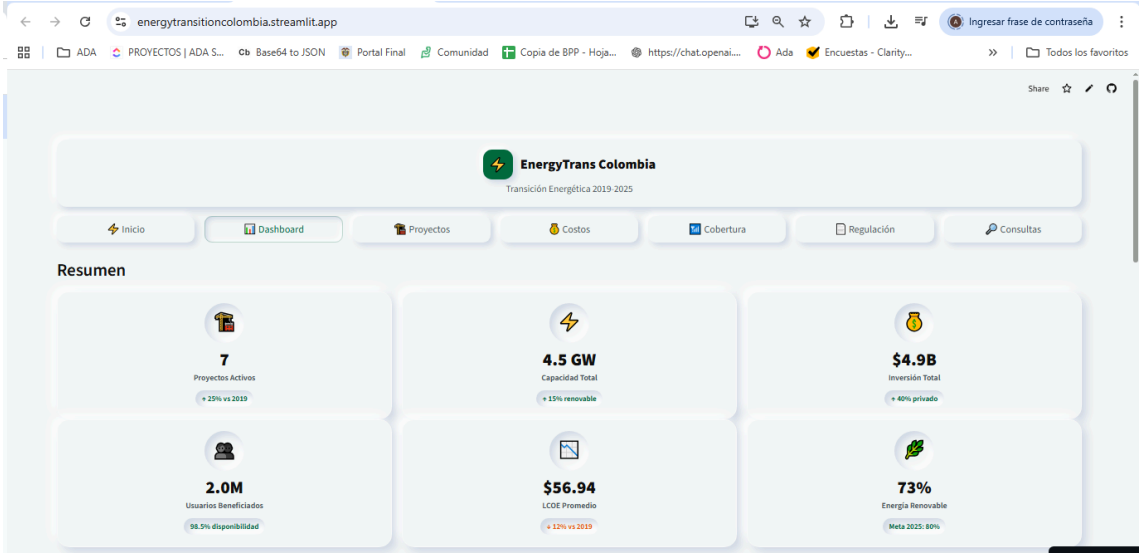

c) Proyectos

Permite explorar el catálogo de proyectos energéticos con tres filtros combinables: tipo de fuente energética, departamento y capacidad mínima instalada en MW. Los resultados se presentan en dos formatos simultáneos: tarjetas visuales tipo card que muestran nombre, ubicación, tipo de energía y LCOE de cada proyecto, y una tabla interactiva con todas las variables disponibles. El módulo cruza las tablas de proyectos, tipos de energía y costos para enriquecer cada registro con su LCOE correspondiente al año disponible.

Figura 3.4. Módulo Proyectos con filtros activos y visualización en tarjetas.

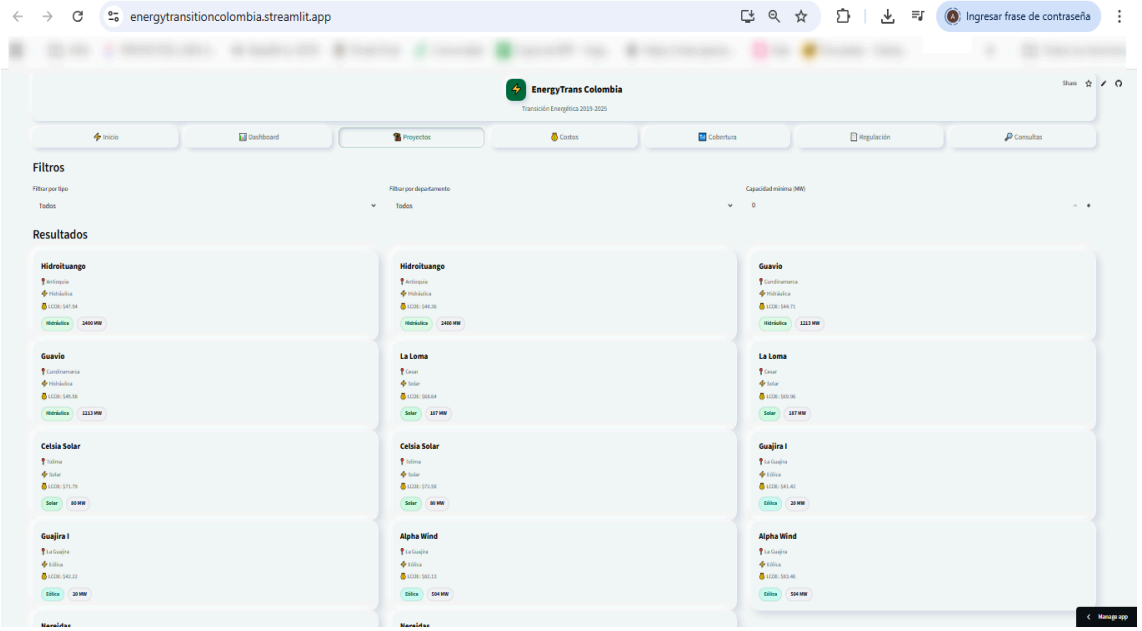

d) Costos

Centraliza el análisis económico de los proyectos. Ofrece cuatro controles de filtrado encadenados: año, tipo de energía, métrica principal (LCOE o CAPEX) y orden de visualización (ascendente o descendente). Adicionalmente, un selector múltiple que permite elegir proyectos específicos para comparación.

Las visualizaciones resultantes son dos gráficos de barras paralelos: LCOE comparativo (USD/MWh) y CAPEX por proyecto (M USD), ambos codificados por color según el tipo de fuente energética con una paleta consistente en toda la aplicación (azul para hidráulica, amarillo para solar, verde para eólica y rojo para geotérmica).Adicional, una tabla inferior resume LCOE, CAPEX, OPEX y costo total calculado. Cada gráfico incluye su bloque de interpretación automática con estadísticos descriptivos y detección de valores atípicos mediante la valla superior de Tukey.

Figura 3.5. Módulo Costos con análisis comparativo de LCOE y CAPEX por proyecto.

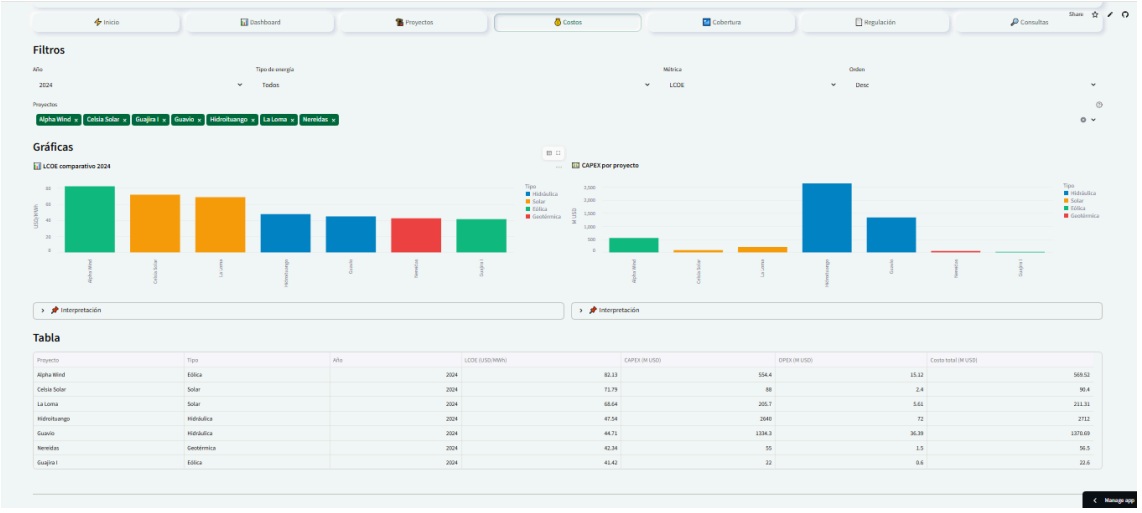

e) Cobertura

Analiza el alcance social de los proyectos a través de dos indicadores: usuarios beneficiados y disponibilidad operativa (%). Presenta un gráfico de barras de usuarios por proyecto y un gráfico de línea con puntos para la disponibilidad, cuyo eje vertical está acotado entre 95% y 100% para amplificar visualmente las diferencias entre proyectos. La tabla inferior cruza los datos de cobertura con la regulación vigente asociada a cada proyecto (Ley 1715 o Ley 2099). Ambos gráficos incluyen interpretación automática con perfil estadístico completo.

Figura 3.6. Módulo Cobertura con usuarios beneficiados y disponibilidad operativa.

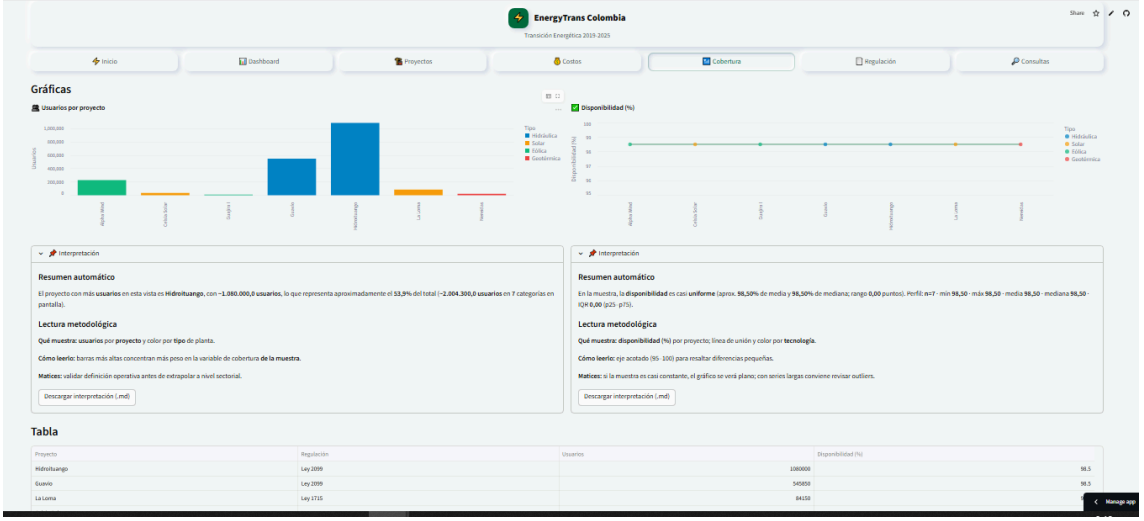

f) Regulación

Documenta el marco normativo que sustenta los incentivos a la transición energética en Colombia. Presenta en tarjetas las dos leyes incluidas en el modelo de datos: la Ley 1715 (deducción de renta del 50%) y la Ley 2099 (exclusión de IVA en bienes y servicios relacionados). Complementa esta información con un gráfico de dona que compara el peso relativo del porcentaje de ahorro declarado por cada ley, acompañado de su correspondiente interpretación metodológica que advierte sobre los matices en la lectura del indicador.

Figura 3.7. Módulo Regulación con marco normativo e impacto de incentivos.

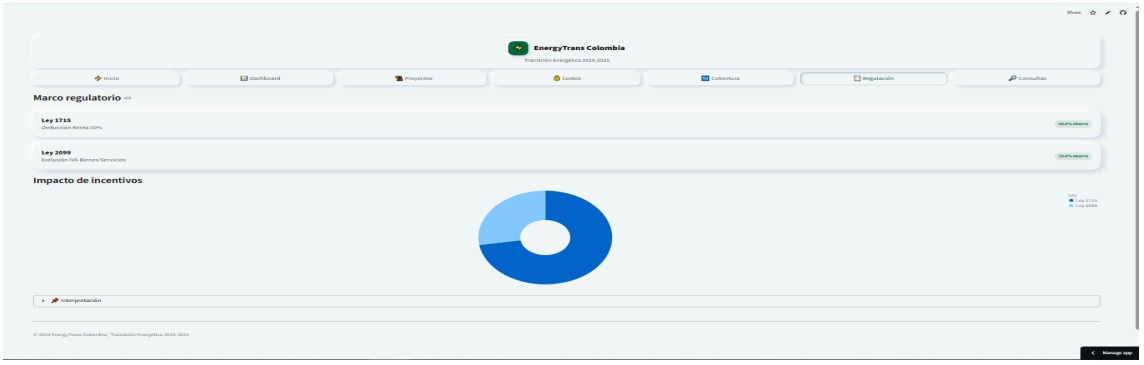

g) Consultas

Implementa un constructor de consultas exploratorias de tipo SQL-mock que permite al usuario seleccionar un tipo de consulta, un filtro por tecnología y un año, y visualizar los resultados de forma dinámica. Los cinco tipos de consulta disponibles son: capacidad por tipo, LCOE promedio, inversión total, cobertura por departamento y eficiencia operativa. El módulo genera y muestra la cadena SQL equivalente a la selección realizada, ejecuta la consulta sobre los datos en memoria y presenta los resultados en una tabla y en un gráfico de barras con interpretación automática. Este módulo está diseñado para simular la experiencia de exploración analítica que tendría lugar con una base de datos productiva conectada.

Figura 3.8. Módulo Consultas con constructor de consultas SQL-mock y visualización de resultados.

4. TECNOLOGÍAS UTILIZADAS

El ecosistema tecnológico se basa principalmente en Python 3.x para el procesamiento lógico y análisis de datos mediante librerías como Pandas y Altair. Para la persistencia de datos, se emplea MySQL Workbench, permitiendo consultas SQL avanzadas y trazabilidad de la información.

En el despliegue de la interfaz web se utiliza Streamlit, mientras que el entorno de desarrollo analítico se apoya en Jupyter Notebooks y Google Colab. La gestión de dependencias se realiza a través de un archivo requirements.txt que garantiza la reproducibilidad del entorno.

5. GUÍA DE INSTALACIÓN Y USO

Para la puesta en marcha del proyecto, es necesario clonar el repositorio y configurar un entorno virtual de Python. Posteriormente, se deben instalar las dependencias mediante el comando 'pip install -r requirements.txt'.

El esquema de la base de datos debe ser cargado en una instancia de MySQL utilizando los scripts proporcionados en la carpeta 'database/'. Finalmente, la aplicación web se ejecuta con el comando 'streamlit run streamlit_app.py', permitiendo al usuario interactuar con los filtros de costos y generación.

6. CONCLUSIONES

A partir del desarrollo del presente proyecto, orientado al análisis de la transición energética en Colombia mediante técnicas de analítica de datos, se establecen las siguientes conclusiones:

- **Integración efectiva de analítica y arquitectura de datos:**

  Se logró diseñar e implementar una arquitectura de tres capas que integra el procesamiento analítico (Notebook), la persistencia estructurada (base de datos MySQL) y la visualización interactiva (Streamlit). Esta integración permitió garantizar coherencia entre los datos generados, almacenados y consumidos, constituyendo una solución robusta y escalable para el análisis del sistema energético.

- **Aporte del análisis exploratorio en la comprensión del sistema energético**

  El desarrollo del análisis exploratorio de datos permitió identificar patrones relevantes en la evolución de la matriz energética, evidenciando tendencias hacia una mayor participación de fuentes renovables no convencionales. Este enfoque facilitó la comprensión de dinámicas complejas del sistema energético, integrando variables técnicas, económicas y ambientales.

- **Importancia de la ingeniería de variables**

  La construcción de indicadores derivados, como la ecoeficiencia, la intensidad de emisiones y el índice de diversificación, permitió enriquecer el análisis y ofrecer una visión más integral del proceso de transición energética. Estos indicadores constituyen herramientas clave para evaluar el desempeño de las distintas tecnologías energéticas.

- **Relevancia del modelo dimensional para análisis energético**

  La implementación de un modelo dimensional tipo estrella demostró ser adecuada para estructurar la información de manera eficiente, facilitando consultas analíticas y permitiendo la escalabilidad del sistema. La correcta separación entre hechos y dimensiones contribuyó a mejorar la claridad del modelo y su aplicabilidad en escenarios reales.

- Los resultados obtenidos evidencian un proceso de transición progresiva hacia una matriz energética más diversificada y sostenible. Se destaca el crecimiento de las fuentes renovables no convencionales, impulsado por su menor impacto ambiental y su potencial de expansión.

  No obstante, persisten desafíos asociados a costos de implementación, estabilidad en la generación y dependencia de fuentes tradicionales, lo cual sugiere la necesidad de estrategias integrales que equilibren sostenibilidad, confiabilidad y viabilidad económica.

- El proyecto logra integrar exitosamente múltiples capas tecnológicas para ofrecer una visión holística de la transición energética. Aunque los datos son de naturaleza sintética, el método analítico propuesto es totalmente transferible a conjuntos de datos oficiales.
- La estructura modular del código y el esquema dimensional de la base de datos permiten una escalabilidad significativa, facilitando la incorporación de nuevas fuentes de energía o variables regulatorias a medida que la política energética nacional evolucione.